

Geração de amostras sintéticas de espectros de XRF via Variational Autoencoder

Foi desenvolvido um modelo generativo baseado em Variational Autoencoder (VAE) para a geração de espectros sintéticos de XRF, buscando preservar tanto a estrutura espectral quanto as propriedades estatísticas dos dados reais. O desenvolvimento do modelo envolveu uma série de etapas críticas, desde a definição do pré-processamento até o ajuste fino da arquitetura e dos hiperparâmetros.

Uma das primeiras dificuldades encontradas esteve relacionada ao pré-processamento dos dados. Inicialmente, foram testadas abordagens como centralização na média e normalização simples. No entanto, essas estratégias não foram suficientes para garantir estabilidade numérica durante o treinamento, resultando em problemas como a ocorrência de valores NaN nas variáveis latentes (z_mean , z_log_var e z). Esse comportamento foi associado à explosão da variância no espaço latente, especialmente devido ao termo exponencial presente no processo de amostragem do VAE. A adoção do escalonamento via StandardScaler (média zero e variância unitária) foi fundamental para estabilizar o treinamento, garantindo melhor condicionamento numérico e permitindo a convergência do modelo.

A arquitetura do VAE foi definida com base em redes neurais densas, compostas por um encoder, um espaço latente e um decoder simétrico. Diversas configurações foram testadas, variando-se o número de camadas, o número de neurônios, a função de ativação e a dimensionalidade do espaço latente. Para auxiliar nessa etapa, foi implementado um algoritmo de busca que avaliava diferentes arquiteturas com base em métricas relacionadas ao comportamento estatístico das variáveis latentes. Após diversos testes, a configuração que apresentou melhor desempenho foi a seguinte:

```
# 3. Hiperparâmetros
# =====
hidden_units = [256, 128, 64]
activation = "tanh"
latent_dim = 24
beta = 1e-6
learning_rate = 1e-4
batch_size = 32
epochs = 200

# parâmetro da ponderação da loss de reconstrução
alpha_weight = 2.0
```

O treinamento do modelo apresentou comportamento estável, com redução consistente da função de perda ao longo das épocas, sem indícios de instabilidade ou overfitting significativo, conforme mostrado na Figura 1.




Figura 1. Evolução da função de perda total do VAE durante o treinamento, evidenciando convergência estável e comportamento consistente entre os conjuntos de treino e validação.

A decomposição da função de perda mostrou que a perda de reconstrução foi dominante, enquanto a divergência KL apresentou crescimento gradual ao longo do treinamento, conforme ilustrado nas Figuras 2 e 3.




Figura 2. Evolução da perda de reconstrução ao longo das épocas, indicando melhoria progressiva na capacidade do modelo de reproduzir os espectros originais.




Figura 3. Evolução da divergência KL durante o treinamento, evidenciando o comportamento do espaço latente e o equilíbrio entre regularização e fidelidade de reconstrução.

A avaliação da qualidade da reconstrução foi realizada comparando diretamente os espectros originais e reconstruídos no espaço físico (sem escalonamento). Como observado na Figura 4, o modelo foi capaz de reproduzir com alta fidelidade tanto a posição quanto a intensidade dos principais picos espectrais, além de capturar adequadamente a linha de base.




Figura 4. Comparação entre espectro original e espectro reconstruído pelo VAE, demonstrando elevada fidelidade na reprodução da estrutura espectral.

A avaliação estatística global indicou excelente concordância entre os dados reais e sintéticos. O erro quadrático médio entre os espectros médios foi de aproximadamente 1,35, enquanto o erro associado ao desvio padrão por canal foi de aproximadamente 8,31. As médias globais (62,67 para dados reais e 62,35 para sintéticos) e os desvios padrão globais (79,78 e 78,01, respectivamente) apresentaram forte concordância, indicando que o modelo preserva adequadamente as propriedades estatísticas dos dados.

A geração de espectros sintéticos (Figura 5) demonstrou que o modelo é capaz de produzir amostras visualmente consistentes e fisicamente plausíveis, mantendo a estrutura espectral característica dos dados reais.




Figura 5 Exemplos de espectros sintéticos gerados pelo VAE, evidenciando coerência com os espectros reais.

Para avaliar a estrutura multivariada dos dados, foi realizada uma análise por PCA (Figura 5). Os resultados indicaram que os espectros sintéticos estão inseridos dentro da distribuição dos dados reais, sem formação de clusters artificiais.




Figura 6. Projeção PCA dos espectros reais e sintéticos, evidenciando sobreposição entre as distribuições.

Observou-se, no entanto, uma maior concentração dos dados sintéticos na região central da distribuição, indicando menor cobertura das regiões periféricas. Esse comportamento foi confirmado por métricas de distância no espaço PCA, que mostraram que as distâncias entre dados sintéticos e reais são da mesma ordem de grandeza das distâncias entre dados reais, enquanto as distâncias entre os próprios sintéticos são ligeiramente maiores, indicando boa diversidade interna, porém concentrada em regiões de maior densidade.

Geração condicional de espectros sintéticos via Conditional Variational Autoencoder

Como continuidade do desenvolvimento do modelo generativo, foi implementada uma abordagem baseada em Conditional Variational Autoencoder (cVAE), permitindo associar explicitamente os teores de B aos espectros gerados sinteticamente. Diferentemente do VAE convencional, no qual o modelo aprende apenas a distribuição dos espectros, o cVAE incorpora o valor de referência de B como uma condição adicional tanto no encoder quanto no decoder. Dessa forma, o modelo passa a aprender relações conjuntas entre a estrutura espectral e os teores do nutriente, possibilitando a geração de pares sintéticos compostos por espectro e valor associado de B.

A principal motivação para essa abordagem está relacionada ao objetivo final do trabalho: utilizar os dados sintéticos em estratégias de data augmentation para treinamento de modelos preditivos. Nesse caso, não basta apenas gerar espectros visualmente plausíveis; é necessário que cada espectro sintético esteja associado a um valor de referência fisicamente coerente.

A Figura 7 apresenta exemplos de espectros sintéticos gerados pelo cVAE para diferentes valores de B. Observa-se que o modelo manteve elevada fidelidade na reconstrução da estrutura espectral, preservando adequadamente tanto a linha de base quanto os principais picos presentes nos espectros reais. Além disso, os espectros sintéticos apresentam variabilidade consistente entre si, indicando que o modelo não apenas memoriza os dados originais, mas efetivamente aprende uma representação latente capaz de gerar novas amostras plausíveis.




Figura 7. Exemplos de espectros sintéticos gerados pelo cVAE para diferentes teores de B, evidenciando preservação da estrutura espectral e coerência física dos dados gerados.

Outro aspecto importante está relacionado à distribuição dos valores de B associados aos espectros sintéticos. A Figura 8 mostra a comparação entre a distribuição dos teores de B do conjunto real de treinamento e a distribuição dos valores sintéticos gerados pelo cVAE. Observa-se elevada sobreposição entre ambas as distribuições, indicando que o modelo conseguiu preservar adequadamente a estrutura estatística dos dados originais. Os espectros sintéticos reproduziram satisfatoriamente tanto a região central da distribuição quanto as regiões de maior concentração de amostras.




Figura 8. Comparação entre as distribuições dos teores de B reais e sintéticos gerados pelo cVAE, mostrando elevada concordância estatística entre os conjuntos.

Embora os resultados sejam bastante promissores, observa-se ainda uma menor representatividade das regiões extremas da distribuição, especialmente para valores muito elevados de B . Esse comportamento é esperado em modelos generativos do tipo VAE/cVAE, que tendem a atuar de maneira mais conservadora, concentrando a geração em regiões de maior densidade amostral. Apesar disso, o modelo demonstrou excelente capacidade de preservar coerência espectral e estatística, indicando forte potencial para aplicação em estratégias de aumento de dados.

Os resultados obtidos sugerem que o cVAE pode se tornar uma ferramenta importante para aumentar a densidade amostral em regiões específicas da distribuição de B , contribuindo para o desenvolvimento de modelos preditivos mais robustos, generalizáveis e menos sensíveis à limitação do número de amostras reais. Como próximos passos, pretende-se avaliar quantitativamente o impacto dessas amostras sintéticas no desempenho de modelos de calibração, comparando cenários com e sem data augmentation para técnicas como PLS, Random Forest, MLP e CNN.